



SYDDANSK UNIVERSITET

DET TEKNISKE FAKULTET

MÆRSK MC-KINNEY MØLLER INSTITUTE

**ANALYSE OG DESIGN AF PLATFORM TIL
REALTIDS TALEOVERSÆTTELSE**

Student

Jon Friis Jakobsen

Exam Number: 475136

Indhold

1	Problemformulering	1
1.1	Baggrund og motivation	1
1.2	Problemstilling	1
1.3	Hovedspørgsmål	1
1.4	Underspørgsmål	1
2	Forskningsbidrag og originalitet	2
2.1	Succeskriterier og evalueringsparametre	2
2.2	Minimum Viable Product (MVP)	2
3	Tidsplan	2
3.1	Afgrænsning	3
3.2	Forventet udbytte og perspektivering	3
3.3	Risikostyring	3

1 Problemformulering

1.1 Baggrund og motivation

I en verden præget af stigende globalisering og digitalisering er behovet for effektiv kommunikation på tværs af sprog mere presserende end nogensinde. Tale-til-tale-oversættelse i realtid har potentialet til at nedbryde sprogbarrierer og skabe nye muligheder for samarbejde, videndeling og adgang til information på tværs af grænser [1, 2]. Dette gælder ikke kun for store virksomheder, men også for mindre aktører, offentlige institutioner og civilsamfundet, hvor sproglig inklusion kan have en stor indflydelse på deltagelse og ligestilling [3].

Nuværende løsninger på markedet for tale-til-tale-oversættelse i realtid er primært udviklet og ejet af store teknologivirksomheder som Microsoft, Amazon og Google. Disse platforme er ofte indlejret i større, proprietære økosystemer, hvilket kan gøre dem utilgængelige, dyre eller vanskelige at tilpasse til mindre aktører, open source-miljøer eller specialiserede applikationer. Samtidig mangler der uafhængig forskning i optimale arkitekturprincipper for sådanne systemer, især omkring balancen mellem latenstid, skalerbarhed og robusthed [4, 5].

Markedet for tale-til-tale-oversættelse i realtid er domineret af store teknologivirksomheder som Google (Alphabet Inc.), Microsoft Corporation og Amazon, der tilbyder integrerede løsninger via henholdsvis Google Translate [6], Microsoft Translator [7] og AWS' kombination af Transcribe, Translate og Polly [8–10].

Derfor fokuserer dette projekt på at udvikle og evaluere en alternativ arkitektonisk tilgang baseret på begivenhedsdrevne mikrotjenester [11–13], med et særligt fokus på at optimere balancen mellem latenstid, skalerbarhed og robusthed i tale-til-tale-oversættelse i realtid.

1.2 Problemstilling

Eksisterende forskning i mikrotjenestearkitektur og realtidsoversættelsessystemer omhandler sjældent den komplekse integration af flere AI-komponenter under strenge latenstidskrav. Litteraturen fokuserer primært på at forbedre individuelle komponenter (ASR-modeller, oversættelseskvalitet) eller monolitiske end-to-end-systemer [14–17], men mangler systematisk behandling af distribuerede arkitekturer, der er specifikt designet til tale-til-tale-oversættelse i realtid [4, 5].

Især er der behov for empirisk viden om, hvordan hændelsesdrevet kommunikation kan optimeres til at håndtere den sekventielle datastrøm fra tale til tale gennem flere behandlingstrin, samtidig med at systemet kan skaleres horisontalt og opretholde høj tilgængelighed under varierende belastningsscenarier [18–20].

1.3 Hovedspørgsmål

Hvordan kan en event-drevet mikroservice-arkitektur designes og implementeres til at levere robust og skalerbar realtids tale-til-tale oversættelse med målbar performance-optimering?

1.4 Underspørgsmål

1. Hvilke arkitekturprincipper og designmønstre understøtter en effektiv realtids pipeline til taleoversættelse?
2. Hvilke faktorer påvirker systemets latenstid og evne til at skalere?
3. Hvordan kan disse faktorer måles og optimeres i praksis?
4. Hvordan kan systemet gøres robust og tilgængeligt, selv hvis enkelte komponenter fejler?

5. Hvordan kan systemets performance og kvalitet evalueres og evt. sammenlignes med eksisterende løsninger?

2 Forskningsbidrag og originalitet

Projektet vil bidrage som referencearkitektur for event-drevne realtidsoversættelsessystemer, hvor de centrale arkitektoniske principper og designmønstre analyseres og diskuteres på baggrund af delspørgsmålet om netop disse valg og overvejelser. Den empiriske analyse af performance-trade-offs i microservice-baserede AI-pipelines er baseret på en systematisk indsamling af data om de faktorer, der påvirker systemets latenstid og skalerbarhed, samt hvordan disse faktorer kan måles og optimeres i praksis. Identifikationen af kritiske designmønstre for lav-latency integration af AI-komponenter er også inkluderet i diskussionen af både arkitektur og performance. Udviklingen af en konkret platform og formidling af bedste praksis sigter mod at opnå høj robusthed og muliggøre en sammenligning med eksisterende løsninger, således at systemets styrker og svagheder kan vurderes i forhold til disse alternativer. Endelig danner evaluering og sammenligning rammen for arbejdet med benchmark-datasæt og evalueringsmetoder, mens projektets metodologiske bidrag vedrørende systematisk performanceevaluering og måling af robusthed og skalerbarhed er integreret som en central del af analysen.

2.1 Succeskriterier og evalueringsparametre

Projektets succes evalueres ved at måle systemets svartider, kapacitet, tilgængelighed og ressourceforbrug under test med stigende belastning. Resultaterne sammenlignes med fastsatte krav til svartid, samtidige sessioner og ressourceudnyttelse. Oversættelseskvaliteten vurderes både automatisk og ved menneskelig vurdering i forhold til kommercielle løsninger. Systemets implementeringsevne og dokumentation testes ved installation på en cloudplatform, og fleksibiliteten testes ved udvidelse til et nyt sprogpar. Alle resultater dokumenteres og diskuteres i rapporten.

2.2 Minimum Viable Product (MVP)

Som minimum leverer projektet en event-drevet pipeline, der muliggør live transskribering og oversættelse fra ét sprog til et andet i så tæt på realtid som muligt. Brugeren taler ind i systemet, som transskriberer talen, oversætter teksten og returnerer den oversatte tekst (eventuelt også som syntetisk tale). Fokus er på at demonstrere lav latenstid og robust event-flow mellem komponenterne, hvor hele processen fra input til output sker automatisk og uden manuel indgriben. MVP'en skal kunne demonstreres med integration af eksisterende open source-komponenter for talegenkendelse, maskinoversættelse og tekst-til-tale.

3 Tidsplan

Periode	Aktiviteter	Leverancer
Sep-Okt	Litteraturstudie, kravanalyse	Literature review, Krav specifikationer
Nov-Dec	Arkitekturdesign, teknologieuvaluering	Teknisk arkitektur dokument
Jan-Mar	Implementering, integration testing	MVP demonstrator, fungerende prototype, test suite
April	Performance testing, evaluering	Eksperimentresultater, benchmark data
Maj	Analyse, rapportskrivning	Final thesis, præsentation

3.1 Afgrænsning

Projektet omfatter design og implementering af mikroservice-arkitektur, integration af eksisterende AI-komponenter, evaluering af performance og skalerbarhed samt deployment-strategier til både cloud og on-premise. Udvikling af nye AI-modeller, detaljeret sikkerhedsanalyse, brugergrænsefladedesign, juridiske aspekter og dybdegående cost-optimering er uden for projektets scope.

3.2 Forventet udbytte og perspektivering

Akademisk forventes projektet at resultere i en kandidatafhandling med fokus på performance-optimering i mikroservice-baserede AI-systemer, en open source referenceimplementering samt bidrag til relevante konferencer. På det praktiske plan leveres en funktionsdygtig platform, dokumenterede best practices for deployment og et omkostningseffektivt alternativ til proprietære løsninger. Perspektiver for fremtidig forskning omfatter blandt andet edge deployment, federated learning, integration af multimodale input og automatisk skalering baseret på forudsigt efterspørgsel.

3.3 Risikostyring

Tekniske risici omfatter blandt andet for høj latenstid, skalerbarhedsproblemer og kompleks integration. Disse imødegås med fallback-løsninger, fokus på vertikal skalering og prioritering af kernefunktionalitet. Ressourcemæssige risici såsom tidsoverskridelser og manglende computing-ressourcer håndteres gennem anvendelse af pre-implementerede komponenter, udnyttelse af cloud credits og lokale fallback-muligheder.

Litteratur

- [1] (2024) Speech to speech translation market size & share analysis. Mordor Intelligence. Accessed: 2025-07-30. [Online]. Available: <https://www.mordorintelligence.com/industry-reports/speech-to-speech-translation>
- [2] (2024) 10 stats & breakthroughs in ai speech translation in 2024. KU-DO. Accessed: 2025-07-30, Blog post. [Online]. Available: <https://kudo.ai/blog/the-10-most-important-statistics-breakthroughs-in-ai-speech-translation-from-2024/>
- [3] (2022) Inclusion in education. UNESCO. Tilgængelig: <https://www.unesco.org/en/inclusion-education> (besøgt juli 2025). [Online]. Available: <https://www.unesco.org/en/inclusion-education>
- [4] P. Xu, A. Sharma, and J. Müller, "Scalability and maintainability challenges and solutions in machine learning: Systematic literature review," *arXiv preprint arXiv:2504.11079*, 2025. [Online]. Available: <https://arxiv.org/abs/2504.11079>
- [5] S. Zhang, J. Chen, C.-H. Wang, W.-N. Hsu, K. Peng, S. Karita, Y. Qian, S. Watanabe, and W. Chan, "Direct speech to speech translation: A review," *arXiv preprint arXiv:2503.04799*, 2024. [Online]. Available: <https://arxiv.org/abs/2503.04799>
- [6] (2024) Cloud translation. Google Cloud. Tilgængelig: <https://cloud.google.com/translate> (besøgt juli 2025). [Online]. Available: <https://cloud.google.com/translate>

- [7] (2024) Microsoft translator. Microsoft. Tilgængelig: <https://www.microsoft.com/da-dk/translator/> (besøgt juli 2025). [Online]. Available: <https://www.microsoft.com/da-dk/translator/>
- [8] (2024) Amazon transcribe. Amazon Web Services. Tilgængelig: <https://aws.amazon.com/transcribe/> (besøgt juli 2025). [Online]. Available: <https://aws.amazon.com/transcribe/>
- [9] (2024) Amazon translate. Amazon Web Services. Tilgængelig: <https://aws.amazon.com/translate/> (besøgt juli 2025). [Online]. Available: <https://aws.amazon.com/translate/>
- [10] (2024) Amazon polly. Amazon Web Services. Tilgængelig: <https://aws.amazon.com/polly/> (besøgt juli 2025). [Online]. Available: <https://aws.amazon.com/polly/>
- [11] S. Newman, *Monolith to Microservices: Evolutionary Patterns to Transform Your Monolith*. O'Reilly Media, 2019.
- [12] C. Richardson, *Microservices Patterns: With Examples in Java*. Manning Publications, 2018.
- [13] M. Fowler. (2014) Microservices: A definition of this new architectural term. Accessed: 2025-07-30. [Online]. Available: <https://martinfowler.com/articles/microservices.html>
- [14] D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate," *arXiv preprint arXiv:1409.0473*, 2014.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Łukasz Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [16] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey *et al.*, "Whisper: Robust speech recognition via large-scale weak supervision," *arXiv preprint arXiv:2212.04356*, 2022.
- [17] C. Wang, A. Wu, J. Pino, A. Baevski, M. Auli, and A. Conneau, "Fairseq s2t: Fast speech-to-text modeling with fairseq," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020.
- [18] M. Kleppmann, *Designing Data-Intensive Applications*. O'Reilly Media, 2017.
- [19] (2023) Apache kafka documentation. Accessed: 2025-07-30. [Online]. Available: <https://kafka.apache.org/documentation/>
- [20] (2023) Kubernetes documentation. Accessed: 2025-07-30. [Online]. Available: <https://kubernetes.io/docs/>